



# **Análisis de la Reducción de Dimensionalidad de Señales de ECG para el Análisis Morfológico del Ritmo Cardíaco**

**Piero Emiliano Vizcarra Vargas**

**Orientador: Dra. Ana Maria Cuadros Valdivia**

*Plan de Propuesta presentado al Curso de Tópicos de Ciencia de Datos.*

**UNSA - Universidad Nacional de San Agustín de Arequipa  
Junio de 2025**

# Índice

<b>1. Motivación y Contexto</b>	<b>4</b>
<b>2. Definición del Problema</b>	<b>4</b>
<b>3. Objetivos</b>	<b>5</b>
3.1. Objetivo General . . . . .	5
3.2. Objetivos Específicos . . . . .	5
<b>4. Dataset</b>	<b>5</b>
4.1. Contexto y Objeto de Estudio . . . . .	5
4.2. Atributos Técnicos del Dataset . . . . .	6
4.3. Anotaciones y Rangos de Valores . . . . .	6
4.4. Cuadro Resumen de Tipo de Dato y Significado . . . . .	6
<b>5. Trabajos Relacionados</b>	<b>7</b>
5.1. Problema, Resolución y Dataset . . . . .	7
5.1.1. XAI-reduct: Preservación de la Precisión a Pesar de la Reducción de Dimensionalidad para la Clasificación de Enfermedades Cardíacas Usando IA Explicable . . . . .	7
5.1.2. Un Novedoso Autoencoder Apilado Basado en Transformer para la Reducción de Dimensionalidad de ECG para la Detección de Latidos de Arritmia . . . . .	8
5.1.3. xECGArch: Una Arquitectura de Aprendizaje Profundo Confiable para el Análisis Interpretado de ECG Considerando Características a Corto y Largo Plazo . . . . .	8
5.1.4. SuPreME: Aprendizaje de Representación Multimodal de ECG-Texto . . . . .	8
5.1.5. D-BETA: Un Marco Novedoso para el Pre-entrenamiento de Datos de ECG y Texto . . . . .	9
5.1.6. ECG-JEPA: Aprendizaje de Representación General de Electrocardiogramas de 12 Derivaciones con una Arquitectura Predictiva de Incrustación Conjunta . . . . .	9

5.1.7. Un Enfoque de Aprendizaje Profundo e Interpretable para la Clasificación de Ruido Clínico de ECG a Largo Plazo . . . . .	9
5.1.8. Una Arquitectura de Red Autoencoder de ECG que Incorpora Atención de Bajo Rango (LRA-autoencoder) . . . . .	10
5.1.9. ProtoECGNet: Un Modelo de Aprendizaje Profundo Basado en Prototipos para la Clasificación Interpretable de ECG Multietiqueta . .	10
5.1.10. Aprendizaje Automático Explicable para el Diagnóstico de Neoplasias Mediante Electrocardiogramas: Un Estudio Validado Externamente . . . . .	10
5.2. Tabla Comparativa de Trabajos Relacionados . . . . .	11
<b>6. Pipeline</b>	<b>13</b>

## 1. Motivación y Contexto

El electrocardiograma (ECG) es una herramienta fundamental para la detección de arritmias y otras anomalías cardíacas. Si bien existen modelos capaces de clasificar latidos cardíacos como normales o patológicos, estos enfoques suelen comportarse como “cajas negras”, lo que limita la interpretación clínica de sus decisiones. En particular, los modelos tradicionales se centran en identificar si hay una anomalía, pero no permiten localizar o visualizar fácilmente qué segmento específico de la señal la origina.

Frente a ello, surgen enfoques que proponen utilizar representaciones latentes (embeddings) de las señales, permitiendo comprimir y estructurar la información de manera significativa. A partir de este espacio latente, es posible analizar qué regiones de la señal original son responsables de una determinada clasificación, abriendo la puerta a modelos explicables e incluso generativos que permitan reconstruir o señalar las causas de una anomalía.

Este trabajo explora el uso del análisis inverso del espacio latente como una vía para detectar e interpretar eventos anómalos en señales multicanal de ECG.

## 2. Definición del Problema

La creciente disponibilidad de datos de ECG multicanal plantea oportunidades para aplicar técnicas modernas de ciencia de datos. Sin embargo, existe una brecha entre la capacidad de los modelos para clasificar patrones complejos y la necesidad clínica de entender y localizar los orígenes de dichas anomalías.

El problema no es solo determinar si existe una anomalía, sino también: ¿qué parte de la señal la provoca?, ¿cómo podemos explicarlo en términos clínicos?, ¿podemos reconstruir esa señal desde su representación comprimida?

Esto plantea el reto de desarrollar un pipeline de análisis que:

- Genere representaciones latentes significativas de señales ECG.
- Permita proyectar de manera inversa una anomalía detectada al dominio temporal original.
- Facilite una interpretación clínica de los resultados desde una perspectiva de ciencia de datos.

## 3. Objetivos

### 3.1. Objetivo General

Desarrollar un sistema de análisis e interpretación de señales ECG multicanal basado en representaciones latentes, que permita localizar segmentos responsables de anomalías a través de análisis inverso del espacio latente.

### 3.2. Objetivos Específicos

- Implementar un modelo que represente señales ECG en un espacio latente compacto.
- Diseñar un mecanismo para mapear segmentos del espacio latente de vuelta al dominio temporal.
- Evaluar si la proyección inversa permite identificar la localización precisa de anomalías cardíacas.
- Comparar la utilidad clínica del enfoque propuesto frente a métodos de clasificación tradicionales.

## 4. Dataset

### 4.1. Contexto y Objeto de Estudio

El dataset en cuestión es una colección de 48 extractos de media hora de grabaciones de ECG ambulatorio de dos canales, obtenidos de 47 sujetos. Estas grabaciones fueron recolectadas por el Laboratorio de Arritmias BIH entre 1975 y 1979.

El objetivo principal de este dataset es proporcionar un recurso para el estudio y desarrollo de algoritmos de detección y clasificación de arritmias cardíacas. Esto se refleja en la selección de las grabaciones:

- 23 grabaciones fueron escogidas al azar de un conjunto más amplio de 4000 registros, representando una población mixta de pacientes hospitalizados (60 %) y ambulatorios (40 %).
- Las 25 grabaciones restantes fueron seleccionadas específicamente para incluir arritmias menos comunes pero clínicamente significativas que no estarían bien representadas en una muestra aleatoria, enriqueciendo así la diversidad de patrones de arritmia disponibles para el estudio.

### 4.2. Atributos Técnicos del Dataset

El dataset posee los siguientes atributos técnicos clave:

- **Número de Registros:** 48 extractos de media hora (de 47 sujetos).
- **Canales de Grabación:** Cada registro contiene grabaciones de dos canales de ECG simultáneamente.
- **Frecuencia de Muestreo:** Las señales se digitalizaron a 360 muestras por segundo por canal. Esto significa que por cada segundo de grabación y para cada derivación, se tomaron 360 puntos de datos.
- **Resolución:** La resolución de la digitalización es de 11 bits en un rango de 10 mV. Esto determina la precisión con la que se registran los valores de voltaje.

### 4.3. Anotaciones y Rangos de Valores

Una característica distintiva de este dataset es su exhaustiva anotación:

- **Anotaciones:** Cada registro fue anotado de forma independiente por dos o más cardiólogos. Las discrepancias se resolvieron para crear anotaciones de referencia legibles por computadora para cada latido. En total, hay aproximadamente 110,000 anotaciones de latidos cardíacos.

Respecto a los rangos de valores, la resolución de 11 bits en un rango de 10 mV implica lo siguiente:

- **Rango Físico de Voltaje:** Las señales de ECG están contenidas dentro de un rango de 10 mV. Esto suele interpretarse como un rango de  $-5$  mV a  $+5$  mV, o un rango similar de 0 a 10 mV dependiendo de la calibración y el offset. Los valores de la señal (MLII, V5, V1, V2, V4) se expresan en milivoltios (mV).
- **Significado del Rango:** Este rango define los valores máximos y mínimos que un latido cardíaco normal o una arritmia pueden alcanzar dentro de la digitalización. Los picos de las ondas R, las depresiones del segmento ST, o las inversiones de la onda T se registrarán dentro de este rango.

### 4.4. Cuadro Resumen de Tipo de Dato y Significado

A continuación, un resumen de las columnas clave y su significado en el contexto de este dataset:

Columna	Tipo de Dato	Significado
<b>MLII / V1 / V2 / V4 / V5</b>	Numérico (float)	Valor de voltaje (mV) de la señal ECG en un instante específico para la derivación correspondiente.
<b>Sample</b>	Numérico (entero/float)	Índice o número secuencial de la muestra de ECG, indicando la posición temporal. No tiene unidad física directa, sino que se convierte a tiempo usando la frecuencia de muestreo.
<b>Símbolo</b>	Categorico (cadena de texto)	Código de anotación para el tipo de latido cardíaco o evento en ese punto de la señal (ej., 'N' para normal, 'V' para ventricular prematuro). Puede ser nulo si no hay anotación.
<b>Descripción</b>	Categorico (cadena de texto)	Descripción textual detallada del 'Símbolo' de anotación. Puede ser nulo.
<b>Registro</b>	Numérico / Categorico (entero/cadena)	Identificador único del sujeto o de la grabación de ECG a la que pertenece la muestra.

## 5. Trabajos Relacionados

### 5.1. Problema, Resolución y Dataset

#### 5.1.1. XAI-reduct: Preservación de la Precisión a Pesar de la Reducción de Dimensionalidad para la Clasificación de Enfermedades Cardíacas Usando IA Explicable

**Problema:** La falta de transparencia en los modelos de aprendizaje automático para la clasificación de enfermedades cardíacas y la "maldición de la dimensionalidad" que lleva a una clasificación intensiva en recursos [Hossen et al. \(2024\)](#). **Forma de Resolución:** El estudio integra SHAP para el análisis de la contribución y el peso de las características, guiando la reducción de dimensionalidad (selección de características). Luego, se realiza una reclasificación con un subconjunto de características reducido utilizando un modelo XGBoost. Para una explicación adicional, se emplean SHAPASH, LIME, DALEX y PDP [Hossen et al. \(2024\)](#). **Dataset Usado:** Un conjunto de datos disponible públicamente con

13 características para el diagnóstico de enfermedades cardíacas [Hossen et al. \(2024\)](#).

### 5.1.2. Un Novedoso Autoencoder Apilado Basado en Transformer para la Reducción de Dimensionalidad de ECG para la Detección de Latidos de Arritmia

**Problema:** La complejidad computacional debido a la alta dimensionalidad de las señales de ECG y los desafíos con las dependencias a largo plazo y la paralelización limitada en las RNN tradicionales para el procesamiento de ECG [Hossen et al. \(2024\)](#).

**Forma de Resolución:** Propone un modelo de autoencoders apilados de reducción de dimensionalidad de ECG basado en Transformer. El Transformer codifica las señales de ECG en una matriz de características, que luego se reduce dimensionalmente mediante un entrenamiento codicioso no supervisado a través de cuatro capas lineales. La clasificación posterior se realiza utilizando Máquinas de Vectores de Soporte (SVM) [Hossen et al. \(2024\)](#). **Dataset Usado:** Base de datos de arritmias MIT-BIH [Hossen et al. \(2024\)](#).

### 5.1.3. xECGArch: Una Arquitectura de Aprendizaje Profundo Confiable para el Análisis Interpretable de ECG Considerando Características a Corto y Largo Plazo

**Problema:** La naturaleza de "caja negra" de los modelos de aprendizaje profundo limita su aplicabilidad clínica para el análisis de ECG, lo que requiere una mayor interpretabilidad [Goettling et al. \(2024\)](#). **Forma de Resolución:** Presenta una nueva arquitectura de aprendizaje profundo (xECGArch) que utiliza dos Redes Neuronales Convolucionales (CNN) independientes para analizar características a corto plazo (morfológicas) y a largo plazo (rítmicas). Las clasificaciones de estas CNN se combinan en un conjunto, que luego se extiende con varios métodos XAI (por ejemplo, Deep Taylor Decomposition (DTD), SHAP, GradCAM) para "blanquear la caja negra". DTD se identificó como el método más confiable [Goettling et al. \(2024\)](#). **Dataset Usado:** Cuatro bases de datos públicas de ECG (n = 9854 ECGs) para la detección de fibrilación auricular (FA) [Goettling et al. \(2024\)](#).

### 5.1.4. SuPreME: Aprendizaje de Representación Multimodal de ECG-Texto

**Problema:** Dependencia de anotaciones y limitaciones de los métodos existentes de aprendizaje auto-supervisado de ECG (eSSL) que pueden distorsionar la integridad semántica o requerir diseños complejos de tareas pretexto [Huang et al. \(2025a\)](#). **Forma de Resolución:** Aplica Grandes Modelos de Lenguaje (LLM) para extraer entidades clínicas estructuradas de informes de ECG de texto libre, filtra el ruido, mejora el aprendizaje de representación clínica y construye un conjunto de datos etiquetado de alta calidad y granularidad. Supera los métodos multimodales anteriores que se basaban en texto libre sin procesar [Huang et al. \(2025a\)](#). **Dataset Usado:** 771,500 señales de ECG emparejadas con entidades extraídas del conjunto de datos MIMIC-IV-ECG [Huang et al. \(2025a\)](#).



#### 5.1.5. D-BETA: Un Marco Novedoso para el Pre-entrenamiento de Datos de ECG y Texto

**Problema:** Desafíos en la integración de señales de ECG con informes textuales debido a las disparidades de modalidad y la escasez de datos etiquetados para un aprendizaje robusto entre modalidades [Huang et al. \(2024\)](#). **Forma de Resolución:** Propone D-BETA, un marco novedoso que pre-entrena datos de ECG y texto utilizando una arquitectura de autoencoder enmascarado contrastivo. Combina las fortalezas generativas con capacidades discriminativas mejoradas para lograr representaciones robustas entre modalidades. Esto se logra mediante el modelado de modalidad enmascarada, funciones de pérdida especializadas y una estrategia mejorada de muestreo negativo [Huang et al. \(2024\)](#). **Dataset Usado:** Cinco conjuntos de datos públicos [Huang et al. \(2024\)](#).

#### 5.1.6. ECG-JEPA: Aprendizaje de Representación General de Electrocardiogramas de 12 Derivaciones con una Arquitectura Predictiva de Incrustación Conjunta

**Problema:** La escasez de datos etiquetados dificulta el aprovechamiento completo del aprendizaje supervisado en el dominio médico, y los métodos auto-supervisados existentes pueden producir detalles innecesarios (ruido) o tener limitaciones con la pérdida L2 [Gao et al. \(2024\)](#). **Forma de Resolución:** Introduce ECG-JEPA, un modelo de Aprendizaje Auto-Supervisado (SSL) para el análisis de ECG de 12 derivaciones que aprende representaciones semánticas de datos de ECG prediciendo en el espacio latente oculto, evitando la necesidad de reconstruir señales en bruto. Incorpora un mecanismo de atención enmascarado especializado llamado Cross-Pattern Attention (CroPA) [Gao et al. \(2024\)](#). **Dataset Usado:** La unión de varios conjuntos de datos de ECG abiertos, totalizando aproximadamente 180,000 muestras [Gao et al. \(2024\)](#).

#### 5.1.7. Un Enfoque de Aprendizaje Profundo e Interpretable para la Clasificación de Ruido Clínico de ECG a Largo Plazo

**Problema:** Dificultad para interpretar el contenido clínico de ECG ruidosos y la necesidad de explicabilidad en los modelos de aprendizaje profundo para la clasificación de ruido clínico [Gómez-Sánchez et al. \(2024\)](#). **Forma de Resolución:** Desarrolla dos conjuntos de Redes Neuronales Convolucionales (CNNs) (una CNN 1D diseñada desde cero y CNNs 2D pre-entrenadas ajustadas mediante aprendizaje por transferencia) y dos arquitecturas de Autoencoder (AE) para proporcionar interpretabilidad del modelo explotando la regionalización de datos en los espacios latentes [Gómez-Sánchez et al. \(2024\)](#). **Dataset Usado:** Una base de datos etiquetada según la gravedad clínica [Gómez-Sánchez et al. \(2024\)](#).

#### 5.1.8. Una Arquitectura de Red Autoencoder de ECG que Incorpora Atención de Bajo Rango (LRA-autoencoder)

**Problema:** Los modelos de redes neuronales predominantes a menudo ignoran las características de dimensión espacial inherentes a las señales de ECG [Yu et al. \(2024\)](#). **Forma de Resolución:** Propone un LRA-autoencoder diseñado para capturar características espaciales potenciales de las señales de ECG interpretando las señales desde una perspectiva espacial y extrayendo correlaciones entre diferentes puntos de la señal utilizando la Descomposición de Valores Singulares (SVD). Asigna estas características espaciales como pesos a las señales de ECG [Yu et al. \(2024\)](#). **Dataset Usado:** No especificado en el documento.

#### 5.1.9. ProtoECGNet: Un Modelo de Aprendizaje Profundo Basado en Prototipos para la Clasificación Interpretable de ECG Multietiqueta

**Problema:** La falta de explicaciones transparentes y fieles en la clasificación de ECG basada en aprendizaje profundo, y las limitaciones de los métodos post-hoc. Los modelos basados en prototipos existentes se limitan a la clasificación de ritmo de una sola etiqueta y a señales de una o dos derivaciones [Huang et al. \(2025b\)](#). **Forma de Resolución:** Introduce ProtoECGNet, un modelo de aprendizaje profundo basado en prototipos para la clasificación interpretable de ECG multietiqueta. Emplea una arquitectura estructurada de múltiples ramas que refleja los flujos de trabajo de interpretación clínica, integrando una CNN 1D con prototipos globales para la clasificación del ritmo y una CNN 2D con prototipos localizados en el tiempo para el razonamiento basado en la morfología [Huang et al. \(2025b\)](#). **Dataset Usado:** No especificado en el documento.

#### 5.1.10. Aprendizaje Automático Explicable para el Diagnóstico de Neoplasias Mediante Electrocardiogramas: Un Estudio Validado Externamente

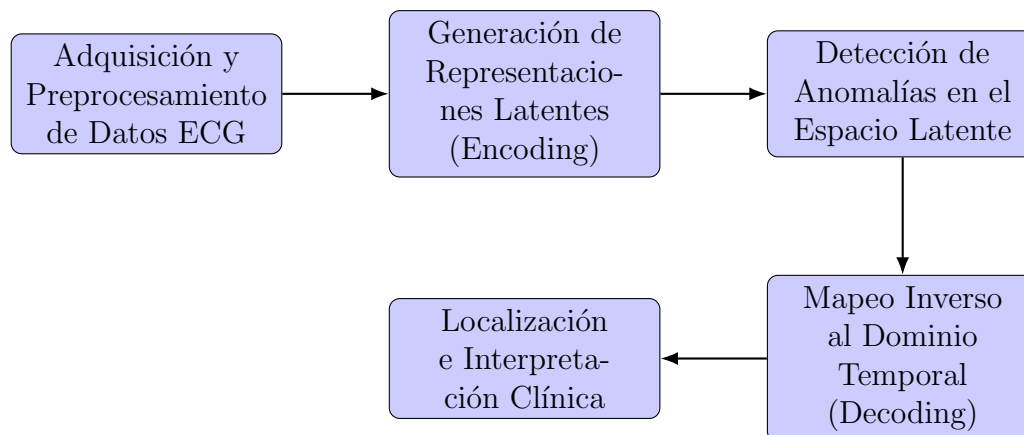
**Problema:** Los métodos de diagnóstico actuales para las neoplasias suelen ser invasivos, costosos e inaccesibles para muchas poblaciones [Jia et al. \(2024\)](#). **Forma de Resolución:** Explora la aplicación de modelos de aprendizaje automático para analizar las características del ECG para el diagnóstico de neoplasias. Desarrolla una tubería que integra modelos basados en árboles con valores de Shapley para la explicabilidad [Jia et al. \(2024\)](#). **Dataset Usado:** Cohortes de validación interna y externa a gran escala [Jia et al. \(2024\)](#).

## 5.2. Tabla Comparativa de Trabajos Relacionados

Trabajo	Problema Principal	Método de Resolución Clave	Dataset Usado
XAI-reduct <a href="#">Hossen et al. (2024)</a>	Opacidad del modelo, problema de la dimensionalidad	SHAP para selección de características, XGBoost	Dataset público con 13 características - Heart Disease Dataset
Transformer-Based Stacked Auto-encoders <a href="#">Hossen et al. (2024)</a>	Complejidad computacional, dependencias a largo plazo en RNNs	Autoencoders apilados basados en Transformer, SVM	MIT-BIH Arrhythmia database
xECGArch <a href="#">Goettling et al. (2024)</a>	Carácter de “caja negra” de DL en ECG	CNNs duales (corto/largo plazo), XAI (DTD, SHAP)	Cuatro bases de datos públicas de ECG (9854 ECGs)
SuPreME <a href="#">Huang et al. (2025a)</a>	Dependencia de anotaciones, distorsión semántica en eSSL	LLMs para extracción de entidades, aprendizaje multimodal	MIMIC-IV-ECG (771,500 ECGs)
D-BETA <a href="#">Huang et al. (2024)</a>	Disparidades de modalidad, escasez de datos etiquetados (ECG-Texto)	Autoencoder enmascarado contrastivo multimodal	Cinco conjuntos de datos públicos
ECG-JEPA <a href="#">Gao et al. (2024)</a>	Escasez de datos etiquetados, ruido en SSL	Modelado en espacio latente, Cross-Pattern Attention (CroPA)	Unión de varios datasets abiertos (180,000 muestras)

Deep Interpretable Learning <a href="#">Gómez-Sánchez et al. (2024)</a>	Ruido clínico, necesidad de interpretabilidad	CNNs, Autoencoders para interpretabilidad en espacios latentes	Base de datos con ruido clínico
LRA-autoencoder <a href="#">Yu et al. (2024)</a>	Ignora características de dimensión espacial en ECG	Autoencoder con atención de bajo rango (SVD)	No especificado
ProtoECGNet <a href="#">Huang et al. (2025b)</a>	Falta de explicaciones fieles, limitaciones de prototipos existentes	Modelo basado en prototipos multirama, clasificación multietiqueta	No especificado
ML para Neoplasias <a href="#">Jia et al. (2024)</a>	Diagnóstico invasivo/costoso de neoplasias	Modelos basados en árboles, Shapley values para explicabilidad	Cohortes de validación interna/externa

## 6. Pipeline



### 1. Adquisición y Preprocesamiento de Datos ECG

- **Paso 1.1: Carga de Datos:** Se cargarán los 48 extractos de grabaciones de ECG de media hora, provenientes de 47 sujetos. Estas grabaciones, recolectadas por el Laboratorio de Arritmias BIH entre 1975 y 1979, contienen dos canales de ECG simultáneamente.
- **Paso 1.2: Digitalización y Frecuencia de Muestreo:** Se confirmará que las señales fueron digitalizadas a 360 muestras por segundo por canal. Esto significa 360 puntos de datos por segundo para cada derivación.
- **Paso 1.3: Resolución y Rango de Voltaje:** Se manejará la resolución de 11 bits en un rango de 10 mV, interpretando los valores de voltaje (MLII, V5, V1, V2, V4) en milivoltios (mV) dentro de un rango de, por ejemplo, -5 mV a +5 mV.
- **Paso 1.4: Limpieza de Ruido y Filtrado:** Se aplicarán técnicas de filtrado para eliminar ruido y artefactos de las señales ECG, preparando los datos para un análisis preciso.
- **Paso 1.5: Segmentación de Latidos:** Las señales se segmentarán en latidos individuales, utilizando las anotaciones existentes que corresponden a aproximadamente 110,000 anotaciones de latidos cardíacos, resueltas por dos o más cardiólogos. Esto permitirá un análisis centrado en la morfología de cada latido.

### 2. Generación de Representaciones Latentes (Encoding)

- **Paso 2.1: Selección del Modelo de Codificación:** Se implementará un modelo que represente las señales ECG en un espacio latente compacto. Se considerarán arquitecturas como autoencoders (similares a las mencionadas en <sup>.A</sup> novel transformer-based ECG dimensionality reduction stacked auto-encoders.<sup>o</sup> <sup>.An</sup> ECG autoencoder network architecture incorporating low-rank attention (LRA-autoencoder)”), o modelos basados en Transformers para capturar dependencias a largo plazo y características espaciales.

- **Paso 2.2: Entrenamiento del Modelo:** El modelo será entrenado para comprimir la información de las señales ECG multicanal en un espacio de menor dimensionalidad, asegurando que las características esenciales para la detección de anomalías se preserven.

### 3. Detección de Anomalías en el Espacio Latente

- **Paso 3.1: Análisis del Espacio Latente:** Una vez que las señales de ECG se han transformado en representaciones latentes, se aplicarán algoritmos para identificar patrones que correspondan a anomalías cardíacas. Esto podría incluir técnicas de clustering para agrupar latidos similares, o métodos de detección de valores atípicos para identificar latidos que se desvían significativamente de los patrones normales.
- **Paso 3.2: Clasificación de Anomalías:** Se utilizarán las anotaciones de referencia (códigos como 'N' para normal, 'V' para ventricular prematuro, etc.) para entrenar o validar clasificadores en el espacio latente que distingan entre latidos normales y patológicos.

### 4. Mapeo Inverso al Dominio Temporal (Decoding)

- **Paso 4.1: Diseño del Mecanismo de Mapeo Inverso:** Se diseñará e implementará un mecanismo para mapear segmentos del espacio latente de vuelta al dominio temporal original de la señal. Esto es fundamental para abordar el problema de localizar qué parte de la señal provoca la anomalía y cómo reconstruir esa señal desde su representación comprimida.
- **Paso 4.2: Reconstrucción de Segmentos Anómalos:** Las representaciones latentes identificadas como anómalas en el paso anterior se utilizarán para reconstruir o señalar los segmentos específicos de la señal ECG original que las generaron.

### 5. Localización e Interpretación Clínica

- **Paso 5.1: Identificación Precisa de Anomalías:** Se evaluará si la proyección inversa permite identificar la localización precisa de anomalías cardíacas en el dominio temporal. Esto implica correlacionar los segmentos reconstruidos con las anotaciones de los cardiólogos para verificar la exactitud de la localización.
- **Paso 5.2: Comparación con Métodos Tradicionales:** Se comparará la utilidad clínica del enfoque propuesto (basado en el análisis inverso del espacio latente) frente a métodos de clasificación tradicionales. Esto permitirá evaluar si el sistema ofrece una mejor interpretabilidad y capacidad para explicar las decisiones del modelo en términos clínicos.
- **Paso 5.3: Presentación de Resultados Interpretables:** Los resultados se presentarán de una manera que facilite la interpretación clínica, permitiendo a los profesionales entender y localizar los orígenes de las anomalías.

## Referencias

- Gao, H., Barker, J., Li, Y., and Lo, B. (2024). Learning general representation of 12-lead electrocardiogram with a joint-embedding predictive architecture. *arXiv*. Accessed: 2025-06-13.
- Goettling, M., Hammer, A., Malberg, H., and Schmidt, M. (2024). xecgarch: A trustworthy deep learning architecture for interpretable ecg analysis considering short-term and long-term features. *PMC*. Accessed: 2025-06-13.
- Gómez-Sánchez, E. J., Pueyo, E., Laguna, P., and Milagro, J. (2024). A deep and interpretable learning approach for long-term ecg clinical noise classification. *PubMed*. Accessed: 2025-06-13.
- Hossen, M. S., Islam, M. M., Islam, T., and Islam, M. R. (2024). An evaluation of dimensionality reduction and classification techniques for cardiac disease diagnosis from ecg signals with various deep learning classifiers. *ResearchGate*. Accessed: 2025-06-13.
- Huang, Z., Xu, Y., and Li, J. (2024). D-beta: A novel framework for ecg and text data pre-training. *arXiv*. Accessed: 2025-06-13.
- Huang, Z., Xu, Y., Li, J., and Liu, C. (2025a). Supreme: Multimodal ecg-text representation learning. *arXiv*. Accessed: 2025-06-13.
- Huang, Z., Xu, Y., and Liu, C. (2025b). Protoecgnet: A prototype-based deep learning model for interpretable multi-label ecg classification. *arXiv*. Accessed: 2025-06-13.
- Jia, Z., Zhang, H., Chen, H., and Xu, X. (2024). Explainable machine learning for neoplasms diagnosis via electrocardiograms: An externally validated study. *arXiv*. Accessed: 2025-06-13.
- Yu, Y., Chen, J., and Chen, D. Z. (2024). An ecg autoencoder network architecture incorporating low-rank attention (lra-autoencoder). *PMC*. Accessed: 2025-06-13.